1.LSTM实验部分

* 数据集介绍

本次实验是一个简单的情感分类问题，给定一句话，判断是否有恶意。数据集来源(https://drive.google.com/uc?export=download&id=1dPHIl8ZnfDz_fxNd2ZeBYedTat2lfxcO),其中包含有标注训练集、未标注训练集以及测试集。

* 数据处理

首先，将模型中出现的单词都映射成具有对应(feature)的vector，具体的方法可以使用Skip-grams(SG).

```
def train_word2vec(x):
    # 訓練 word to vector 的 word embedding
    model = word2vec.Word2Vec(x, size=250, window=5, min_count=5, workers=12, iter=10, sg=1)
    return model
```

然后再将这个model保存下来。

* LSTM模型搭建

通过上一步训练得到的模型，将train_x转换为我们需要的数据形式，并且令每个词向量的长度是固定的。以训练集为例，得到的结果如下:

```
loading data ...
Get embedding ...
loading word to vec model ...
get words #16551
total words: 16553
embedding.shape:  torch.Size([16553, 250])
train_x shape:  torch.Size([200000, 20])
```

统计得到的总次数为16553，最后的输出结果的维度为250；训练集中的20000条数据，令每句话的词数为20；总取隐含层的最后一层，作为词向量的feature，输出的维度为150,作为LSTM网络的inputs。

根据embedding矩阵的参数，搭建如下的网络：

```
class LSTM_Net(nn.Module):
    def __init__(self, embedding, embedding_dim, hidden_dim, num_layers, dropout=0.5, fix_embedc
        super(LSTM_Net, self).__init__()
        # 製作 embedding layer
        self.embedding = torch.nn.Embedding(embedding.size(0),embedding.size(1))
        self.embedding.weight = torch.nn.Parameter(embedding)
        # 是否將 embedding fix 住，如果 fix_embedding 為 False，在訓練過程中，embedding 也會跟著被訓
        self.embedding.weight.requires_grad = False if fix_embedding else True
        self.embedding_dim = embedding.size(1)
        self.hidden_dim = hidden_dim
        self.num_layers = num_layers
        self.dropout = dropout
        self.lstm = nn.LSTM(embedding_dim, hidden_dim, num_layers=num_layers, batch_first=True)
        self.classifier = nn.Sequential( nn.Dropout(dropout),
                                         nn.Linear(hidden_dim, 1),
                                         nn.Sigmoid() )
```

关于最后的DNN，在全连接层先调用dropout()函数，防止模型过拟合；然后调用linear函数，输入为hidden_dim，也就是feature的维度。

2.Explainable/Interpretable ML

* why Explainable/Interpretable ML

深度学习中的模型对我们来讲，一般都是黑箱模型，大多时候我们并不知道它为什么会得到这样的结论，所以需要设计这样的ML模型，使得它能够告诉我们真的有学到东西。线性模型是可解释的，所以我们可以通过线性模型，尝试取解释神经网络模型。

* Explain the Decision

假设有一个图像分类的模型，当我们想要知道为什么这个分类器会做出这样的决策，比如判断图片中有一只猫，或者机器为什么认为这个特征是重要的，可以通过一种比较基础的方法：

$$object\ x \rightarrow Components: \{x_1, x_2, \ldots, x_n\}$$

这里的x_i可以是像素；在文本分类问题中，x_i可以是一个word。我们可以选择改变其中一个x，然后观察对最终的决策是否有很大的影响，如果是就说明这是很重要的特征，也是机器判断的标准之一，这样我们也就部分解释了这个模型。

* Limitation of Gradient based Approaches

如果只是单纯考虑目标函数对特征的导数的大小，那么会遇到很大的局限。在处理现实问题中，一般会遇到梯度饱和(Gradient Saturation)的问题，所以不能单纯地考虑梯度值的大小。为了解决这个问题，可以考虑参考Integrated gradient、DeepLIFT。

* Using a model to explain another

通常我们没法用线性模型完整得解释一个神经网络模型，但是，可以去模仿神经网络的局部。比如我们可以给出神经网络模型计算的损失函数值函数图像，然后用线性模型去模仿局部的图像，从而尝试去解释。

3.Adversarial Attack

* 动机

设计深度学习的模型，不仅仅需要考虑它是否有效，而且还要考虑它能否抵御来自第三方的恶意攻击。假设有一张图片，图片中有一只小猫，在正常的情况下，分类器可以很好得判断出图片中的动物，但是当外界给图片加上一些噪音时，分类器就不能正确判断了.

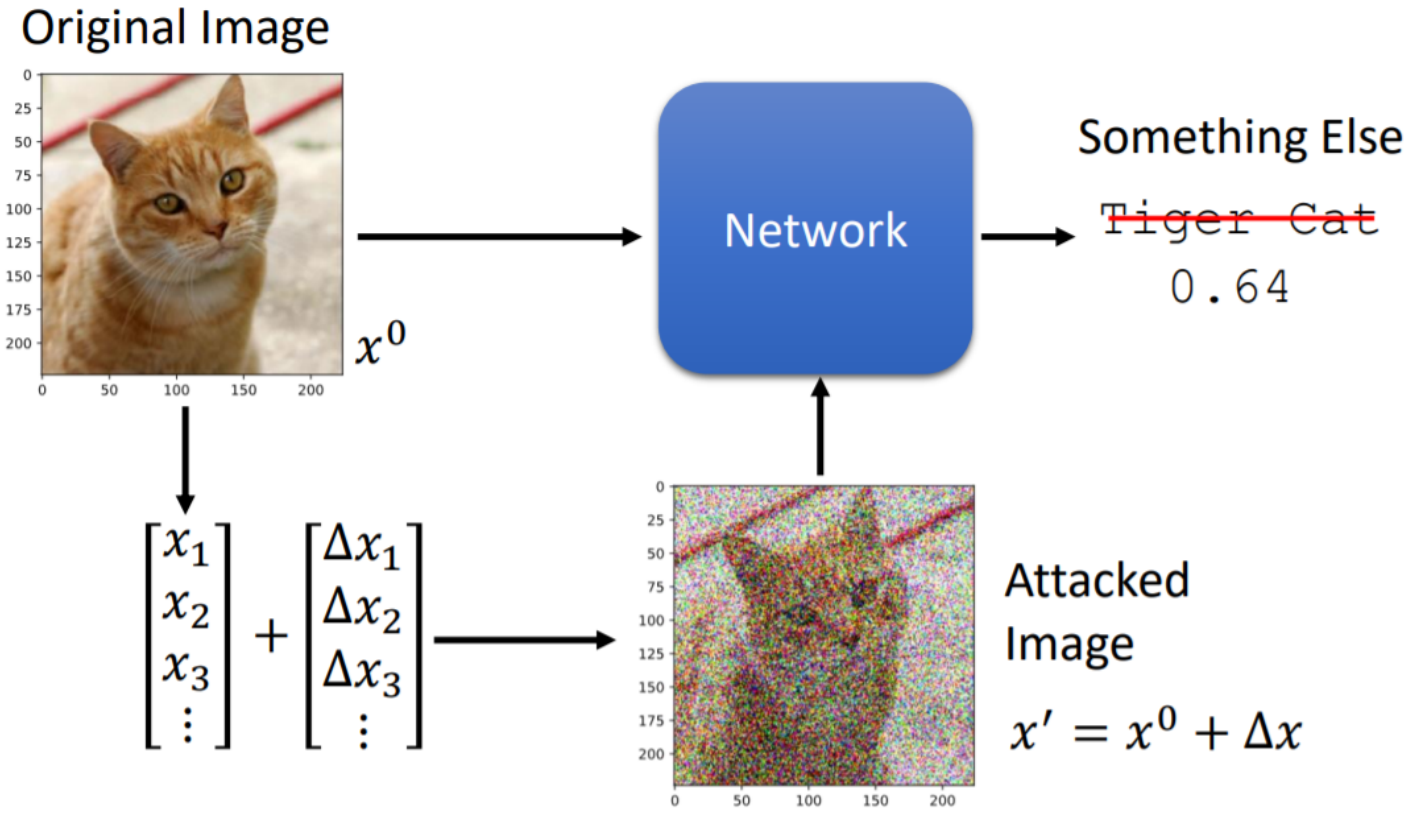

经过修改的图片是可以很明显得看出添加过噪音的。

* Loss Function for Attack

一般为了不让设计者发现训练数据是经过修改的，所以会增加一个限制：$d(x^0, x') < \epsilon$,假设模型训练的目标函数是这样的：

$$L_{train}(\theta) = C(y^0, y^{true})$$

那么可以设计这样的目标函数:

$$L(x') = -C(y', y^{true}) + C(y', y^{false})$$

其中，$-C(y', y^{true})$的绝对值需要尽量变大，$C(y', y^{false})$的值需要尽量小。关于$d(x^0, x')$,主要有两种计算方式，取决于应用的领域。

* How to Attack

原理上和原来的Gradient decent方法是一样的，只是将原来的参数θ替换为精心修改过的x'：

$$x^* = arg\ min\ L(x')$$

设计如下的算法：

$Start\ from\ origin\ image\ x^0$
$For\ t = 1\ to\ T$
    $x^t \leftarrow x^{t-1} - \eta \nabla L(x^{t-1})$
    $if\ d(x^0, d^t) > \epsilon$
        $x^t \leftarrow fix(x^t)$

其中，$fix()$函数的定义如下:

$def\ fix(x^t)$:
    $For\ all\ x\ fulfill\ d(x^0, d^1) < \epsilon$
    $return\ the\ one\ closest\ to\ x^t$

* Attack Approaches